

Adaptación de BERT para NER

U2T01 | Jonathan | Resultados experimentales

1. Objetivo y diseño

Reconocer personas (PER), organizaciones (ORG), lugares (LOC) y entidades misceláneas (MISC). Se compararon ajuste parcial de las dos últimas capas y ajuste completo de BERT-base-cased. La hipótesis fue que el ajuste completo mejoraría F1, a cambio de mayor costo de entrenamiento.

Se usaron 14,041 oraciones para entrenamiento, 3,250 para validación y 3,453 para test. Se conservaron las particiones originales de CoNLL-2003; test no intervino en la selección.

2. Preprocesamiento y reproducibilidad

WordPiece con mayúsculas conservadas. Etiqueta sólo en la primera subpalabra; -100 en continuaciones, tokens especiales y padding. El sanity-check imprime un batch real y verifica una etiqueta por palabra. No se truncaron oraciones; se verificó el límite de 512 posiciones.

Ambos métodos: semilla 42, 3 épocas, batch efectivo 16, AdamW, LR cabeza 0.001 y encoder 0.00002, warmup del 10%, scheduler lineal y gradient clipping 1.0. Se excluyó decay de bias y LayerNorm. Hardware: NVIDIA GeForce RTX 4060 Laptop GPU; PyTorch 2.6.0+cu124, Python 3.12.14.

Los SHA del modelo/dataset, paquetes, configuración, conteos de parámetros, tiempos e historial se entregan en results/. El checkpoint de cada método se eligió por F1 de validación.

3. Métricas

La métrica principal es F1 micro de entidades (segeval estricto IOB2): una predicción es correcta sólo si coinciden span completo y tipo. Precisión mide falsos positivos y recall mide omisiones. Accuracy por palabra es secundaria por la abundancia de la etiqueta O. Las pérdidas por época permiten examinar convergencia. Los tiempos por época excluyen evaluación y guardado; el total los incluye.

4. Resultados y costo

Método	Parám. entrenables	Val F1 %	Test F1 %	Minutos
parcial	14,182,665	91.71	88.79	1.93
full	107,726,601	95.11	91.54	5.98

Método	Test precisión %	Test recall %	Accuracy %	VRAM GiB
parcial	89.03	88.54	97.75	0.76
full	91.55	91.52	98.28	2.42




Figura 1. Pérdidas y F1 de validación a lo largo del entrenamiento.




Figura 2. Costo total y F1 de test; test se consultó después de seleccionar el método.

5. Selección y alcance de la evidencia

Se seleccionó full por su F1 de validación (95.11%). La diferencia observada respecto a parcial fue 3.40 puntos porcentuales. La selección se registró antes de evaluar test. Se entrenó una sola semilla por método; no se realizaron pruebas de significancia estadística. Aunque la diferencia supera 3 puntos en esta ejecución, una sola semilla no caracteriza su variabilidad.

6. Desglose del modelo elegido

Entidad	Precisión %	Recall %	F1 %	Soporte
PER	96.99	95.67	96.33	1617
ORG	89.23	90.31	89.77	1661
LOC	93.28	93.23	93.25	1668
MISC	80.65	80.77	80.71	702

Las predicciones y etiquetas completas permiten recalcular las métricas. Los primeros veinte casos con desacuerdos se conservan en `error_examples.json` para inspección, referidos por índice del split test. No se han atribuido causas lingüísticas a errores sin inspeccionarlos.

7. Uso, limitaciones y entrega

El modelo ganador y su tokenizador están en `results/full/model/`. La model card documenta métricas y entrenamiento. La publicación Hub requiere el repositorio del equipo; si es privado se debe conceder acceso a `Dexterg83`. Este reporte no afirma que ya esté publicado.

El alcance es inglés periodístico con cuatro tipos de entidad. No se validó generalización a otros idiomas o dominios. Los resultados pueden variar con la semilla, hardware y versiones; pueden persistir sesgos del corpus y del modelo base. La licencia del modelo base no concede derechos de redistribución sobre el corpus Reuters. No se incluye el corpus en el modelo exportado.

8. Referencias

[Devlin et al. BERT \(2018\)](#)

[BERT-base-cased](#)

[CoNLL-2003 en Hugging Face](#)

[CoNLL-2003: tarea original](#)

[Hugging Face: token classification](#)

[segeval](#)