

Planificación y Distribución de Tareas: U2T01 Adapting BERT

Este documento detalla la asignación de tareas y los lineamientos técnicos para cumplir con todos los requerimientos de la asignación **U2T01: Adapting BERT for NLP tasks**.

Se utilizarán **Jupyter Notebooks** para todo el desarrollo (Data Science standard) y se aplicarán buenas prácticas de reproducibilidad.

Asignación de Equipo

Hemos dividido las tareas considerando el hardware disponible. Las tareas token-level y de extracción (más pesadas) van a los equipos con **GPU Local (CUDA)**, mientras que las tareas a nivel de texto, métricas y despliegue van al equipo con **Google Colab (Lightweight)**.

Equipo GPU Local (CUDA) - Tareas de Alta Demanda

(Russel, Jonathan, Rivaldo)

- **Russel:**
 - **Tarea:** Extractive QA (Dataset: rajpurkar/squad - subsample de ~15k).
 - **Responsabilidad:** Implementar head para predecir posiciones de inicio/fin. Comparar al menos dos métodos de adaptación (ej. Partial fine-tuning vs Full fine-tuning).
- **Jonathan:**
 - **Tarea:** Named Entity Recognition - NER (Dataset: Thoestq/conll2003).
 - **Responsabilidad:** Manejo estricto de subwords (etiqueta en la primera sub-palabra, -100 en el resto). Imprimir batch de sanity-check. Comparar dos métodos.
- **Rivaldo:**
 - **Tarea:** Part-of-Speech Tagging - POS (Dataset: universal-dependencies/universal_dependencies, config en_ewt, 17 tags).
 - **Responsabilidad:** Manejo estricto de subwords (regla del -100). Imprimir batch de sanity-check. Comparar dos métodos.

Equipo Google Colab - Tareas Ligeras, Despliegue y Reporte

(Damian, Bianca)

- **Bianca:**
 - **Tarea:** Topic Classification (Dataset: fancyzhx/ag_news, 4 clases).
 - **Responsabilidad:** Es la tarea más ligera (un label por texto). Comparar Feature-based adaptation (ej. Regresión Logística/SVM sobre embeddings congelados) vs Fine-tuning.
- **Damian:**
 - **Tarea:** Orquestación, Testing, Benchmarks y Hugging Face.
 - **Responsabilidad:**

- Crear el script/notebook base para la **carga de tokenizadores y subida a Hugging Face**.
- Unificar las métricas de todos los modelos (loss values, scores por época, segundos por paso/época).
- Consolidar el **Reporte PDF** final (justificaciones, tabla de comparación, referencias).

Requerimientos Técnicos y Buenas Prácticas (¡No Olvidar!)

Para asegurar que todo esté en orden con la rúbrica del "U2T01-1.pdf", todos deben cumplir con lo siguiente en sus Jupyter Notebooks:

1. Modelo Base y Entorno

- **Modelo Obligatorio:** Usar bert-base (110M parámetros) como cuerpo principal. *(Opcional: probar DistilBERT o BERT-large si el tiempo y hardware lo permiten).*
- **Librerías:** Usar el ecosistema de Hugging Face (Transformers, Tokenizers, Datasets, Trainer).
- **Reproducibilidad:** Usar **semillas fijas (fixed seeds)**. Las variaciones de $\pm 1-3$ puntos son ruido, no descubrimientos.

2. Entrenamiento y Learning Rates (CRÍTICO)

- **Dos Grupos de Parámetros (Parameter Groups):** Si hacen *Partial* o *Full fine-tuning*, DEBEN usar dos learning rates distintos:
 - Cabeza nueva (Head): **$\sim 1e-3$** (Alto).
 - Cuerpo pre-entrenado (Encoder layers): **$\sim 2e-5$** (Bajo, para no destruir el pre-entrenamiento).
- **Experimentos:** Por cada tarea, presentar **el modelo final elegido** junto con **una alternativa rechazada** entrenada por ustedes mismos para comparar empíricamente (ej. Feature-based vs Full fine-tuning).

3. Manejo de Subwords (Para NER y POS - Jonathan y Rivaldo)

- La convención obligatoria: La etiqueta real va en la **primera sub-palabra** (ej. de "playing" -> "play").
- Todo el resto de sub-palabras, [CLS], [SEP], y padding **DEBEN** recibir la etiqueta -100 para que CrossEntropyLoss las ignore.
- **Sanity-Check:** Debe haber una celda en el notebook que imprima un batch mostrando los tokens alineados junto a sus etiquetas antes de iniciar el entrenamiento.

4. Entregables y Hugging Face Hub (Damian & Equipo)

- **Notebooks limpios:** Todo el código, configuraciones y requirements.txt.
- **4 Modelos en Hugging Face:**
 - Deben subir el modelo y su **tokenizador** correcto.

- Cada repositorio debe incluir un **Model Card** detallado: datos de entrenamiento, métricas, uso intencionado, limitaciones y referencias.
- Si los repositorios son privados, **dar acceso al usuario Dexterg83**.
- **Reporte PDF:** Documentar el proceso, justificar decisiones técnicas, incluir tabla comparativa (tareas vs métodos) y referencias de papers/código.



Flujo de Trabajo Sugerido

1. **Setup (Día 1):** Clonar repo, instalar dependencias, probar carga de datasets.
2. **Desarrollo Base (Día 2-3):** Implementar el pipeline de tokenización asegurando la regla del -100 donde aplique.
3. **Entrenamiento y Benchmarking (Día 4-5):** Entrenar las dos variantes por tarea. Damian recolecta tiempos y métricas.
4. **Despliegue y Reporte (Día 6-7):** Subir modelos a Hugging Face usando los scripts de Damian. Redactar el PDF final.